

# YOLO 模型评估报告

## 1. 评估概述

本次评估对象为 **yolo26n-set**，模型任务类型为 **目标检测 + 实例分割**，即同时包含 **Box 检测分支** 与 **Mask 分割分支**。

模型目标类别包括：

| 类别    | 含义    |
|-------|-------|
| chirp | 引力波信号 |
| noise | 噪声    |

模型共训练 **257 个 Epoch**。

本次评估数据来源包括两部分：

### 1. 模型内置验证集指标

来源于 **results.csv**、PR 曲线、F1 曲线、Precision 曲线、Recall 曲线及训练曲线图。

### 2. 独立测试集真实检测结果

共 **125 张图像**，仅统计 **chirp 类别** 的实际检测表现。

本次评估核心关注点包括：

- 验证集与独立测试集的一致性
- chirp 类别的召回能力
- 精确率与召回率的平衡
- Box 检测与 Mask 分割分支的相对表现
- 模型是否具备稳定部署价值

## 2. 模型内置验证指标

### 2.1 Box 检测分支

Box mAP@0.5 指标

| 类别          | mAP@0.5 |
|-------------|---------|
| chirp       | 0.779   |
| noise       | 0.772   |
| all classes | 0.775   |

Box 曲线关键结论

| 曲线           | 关键结果                                          |
|--------------|-----------------------------------------------|
| F1 曲线        | 最大 F1 约为 <b>0.780</b>                         |
| 最优 F1 置信度区间  | 约 <b>0.300 ~ 0.500</b>                        |
| Precision 曲线 | 置信度阈值为 <b>0.999</b> 时，Precision 为 <b>1.00</b> |
| Recall 曲线    | 置信度阈值为 <b>0.000</b> 时，Recall 为 <b>0.850</b>   |

第 237 个 Epoch 的 Box 指标

该 Epoch 与 **73.9% 召回率** 对应。

| 指标           | 数值    |
|--------------|-------|
| Precision(B) | 0.858 |
| Recall(B)    | 0.739 |
| mAP50(B)     | 0.760 |
| mAP50-95(B)  | 0.445 |

分析性解读

Box 分支在两个类别上的 mAP@0.5 较为接近，**chirp 为 0.779，noise 为 0.772**，说明检测分支对两类目标的识别能力相对均衡，没有出现某一类别明显失效的情况。

F1 曲线显示最大 F1 约为 **0.780**，且最佳置信度阈值主要分布在 **0.300 ~ 0.500** 区间。这说明模型在中等置信度范围内可以取得较好的精召平衡。

Precision 曲线在高阈值 **0.999** 时达到 **1.00**，表明当模型给出极高置信度预测时，预测结果具有很高可靠性。但 Recall 曲线在低阈值 **0.000** 时最高约为 **0.850**，说明即使充分放宽阈值，仍存在一

定比例的漏检样本，召回上限仍有提升空间。

第 237 个 Epoch 的 Box Recall 为 **0.739**，与独立测试集 chirp 召回率 **73.9%** 完全对齐，说明该验证状态对真实测试场景具有较强参考价值。

## 2.2 Mask 分割分支

### Mask mAP@0.5 指标

| 类别          | mAP@0.5 |
|-------------|---------|
| chirp       | 0.810   |
| noise       | 0.718   |
| all classes | 0.764   |

### Mask 曲线关键结论

| 曲线          | 关键结果                                                                        |
|-------------|-----------------------------------------------------------------------------|
| F1 曲线       | 最大 F1 为 <b>0.770</b>                                                        |
| 最优 F1 置信度阈值 | <b>0.386</b>                                                                |
| Recall 曲线   | 阈值为 <b>0.000</b> 时，chirp Recall 约 <b>0.840</b> ，noise Recall 约 <b>0.790</b> |

### 与 Box 分支对比

| 分支   | chirp mAP@0.5 | noise mAP@0.5 | all classes mAP@0.5 | 最大 F1 |
|------|---------------|---------------|---------------------|-------|
| Box  | 0.779         | 0.772         | 0.775               | 0.780 |
| Mask | 0.810         | 0.718         | 0.764               | 0.770 |

### 分析性解读

Mask 分支在 **chirp 类别** 上表现优于 Box 分支，mAP@0.5 从 **0.779** 提升至 **0.810**，说明模型对 chirp 信号区域的分割质量较好，能够较准确地捕捉目标形态。

但 Mask 分支在 **noise 类别** 上明显弱于 Box 分支，mAP@0.5 为 **0.718**，低于 Box 分支的 **0.772**。这表明 noise 的实例分割边界或区域形态更难稳定学习，可能存在噪声区域形态多样、边界模糊或标注一致性问题。

从 all classes 指标看，Box 分支 mAP@0.5 为 **0.775**，Mask 分支为 **0.764**，两者整体接近。Mask 分支最大 F1 为 **0.770**，略低于 Box 分支的 **0.780**，说明检测框层面的整体稳定性略好，而分割分支在 chirp 上有更强表现，但被 noise 类别拖低了整体均值。

## 2.3 训练曲线表现

训练过程中，train/box\_loss、train/cls\_loss 等训练损失持续平滑下降，未观察到明显震荡。验证集各项损失及 mAP 指标整体稳定，后期未出现崩溃或剧烈波动。

从训练质量看：

- 模型具备稳定收敛特征；
- 未观察到明显过拟合迹象；
- 未观察到明显欠拟合迹象；
- 验证指标与训练损失变化趋势一致，说明训练过程较为健康。

整体判断：模型训练过程稳定，257 个 Epoch 的训练结果可信，当前性能主要受数据难度、类别区分边界和阈值策略影响，而不是训练不稳定导致。

## 3. 独立测试集上的真实性能

### 测试集规模与分布

独立测试集共 125 张图像。

| 样本类型      | 数量  | 占比   |
|-----------|-----|------|
| 真实有 chirp | 83  | 66%  |
| 真实无 chirp | 42  | 34%  |
| 总计        | 125 | 100% |

该测试集正样本占比为 **66%**，负样本占比为 **34%**，整体更偏向 chirp 检测场景，适合重点评估模型对 chirp 信号的发现能力。

### 混淆矩阵

| 真实/预测 | 预测有 chirp | 预测无 chirp |
|-------|-----------|-----------|
|-------|-----------|-----------|

|           |         |         |
|-----------|---------|---------|
| 真实有 chirp | TP = 61 | FN = 22 |
| 真实无 chirp | FP = 7  | TN = 35 |

## 独立测试集指标

| 指标        | 计算方式                                              | 数值    |
|-----------|---------------------------------------------------|-------|
| Recall    | $61 / (61 + 22)$                                  | 73.9% |
| Precision | $61 / (61 + 7)$                                   | 89.7% |
| Accuracy  | $(61 + 35) / 125$                                 | 76.8% |
| F1-score  | $2 \times (0.897 \times 0.739) / (0.897 + 0.739)$ | 81.2% |

## 指标业务含义解读

### Recall = 73.9%

在全部 **83 张真实有 chirp** 的图像中，模型正确检出了 **61 张**，漏检 **22 张**。这说明模型能够发现约 **74%** 的 chirp 样本，但仍有约 **26%** 的真实 chirp 未被检测到。若业务目标偏向预警或尽可能发现引力波信号，则当前召回率仍有继续提升空间。

### Precision = 89.7%

在模型预测为有 chirp 的 **68 张** 图像中，有 **61 张** 为真实 chirp，误报 **7 张**。这说明模型的 chirp 预测结果较可靠，预测为 chirp 时大约 **90%** 是正确的。该特征适合用于高可信候选筛选。

### Accuracy = 76.8%

在全部 **125 张** 测试图像中，模型正确判断 **96 张**。准确率反映整体分类判断能力，但由于测试集中正负样本比例并非完全均衡，Accuracy 应与 Recall、Precision、F1-score 一起解读，不能单独作为主要判断依据。

### F1-score = 81.2%

F1-score 综合考虑 Precision 与 Recall，当前为 **81.2%**。由于 Precision 明显高于 Recall，F1-score 表明模型整体检测质量较好，但性能瓶颈主要来自漏检，而不是误报。

## 4. 综合质量评估

## 4.1 优势

### 1. 验证集与独立测试集召回高度一致

第 237 个 Epoch 的 Box Recall 为 **0.739**，独立测试集 chirp Recall 同样为 **73.9%**。这说明验证集指标对独立测试表现具有较强解释力，模型泛化表现较稳定。

### 2. chirp 检测精确率较高

独立测试集 Precision 为 **89.7%**，说明模型预测 chirp 时误报较少，具备较强的高可信筛选能力。

### 3. Box 分支类别表现均衡

Box 分支 chirp mAP@0.5 为 **0.779**，noise 为 **0.772**，两类差异很小，说明检测框层面的类别识别没有明显偏科。

### 4. chirp 分割质量较好

Mask 分支 chirp mAP@0.5 为 **0.810**，高于 Box 分支 chirp 的 **0.779**。这表明模型不仅能检测 chirp，还能较好地定位 chirp 区域。

### 5. 训练过程稳定

训练损失平滑下降，验证指标稳定，未观察到明显过拟合或欠拟合迹象，说明当前模型结果具备较高可信度。

## 4.2 不足

### 1. chirp 召回率仍有提升空间

独立测试集中 FN = **22**，Recall 为 **73.9%**。对于引力波信号检测这类可能更关注漏检风险的任务，当前漏检比例仍需重点优化。

### 2. Mask 分支 noise 类别偏弱

Mask noise mAP@0.5 为 **0.718**，明显低于 chirp 的 **0.810**，也低于 Box noise 的 **0.772**。这说明 noise 的分割质量是当前 Mask 分支的主要短板。

### 3. 低阈值下召回仍存在上限

Box Recall 曲线在阈值 **0.000** 时约为 **0.850**，Mask chirp Recall 约 **0.840**。即使极大放宽阈值，也仍有一部分目标无法被模型候选框或候选掩膜覆盖。

### 4. 当前模型更偏高精度而非高召回

独立测试集 Precision 为 **89.7%**，Recall 为 **73.9%**，二者存在约 **15.8 个百分点**差距。若部署目标是预警或初筛，需要进一步向高召回方向调优。

## 4.3 验证集与独立测试集对比

| 指标来源                   | 指标           | 数值    | 说明               |
|------------------------|--------------|-------|------------------|
| 内置验证集 Box，第 237 Epoch  | Recall(B)    | 73.9% | 与独立测试集 Recall 对齐 |
| 独立测试集 chirp            | Recall       | 73.9% | 61 / 83          |
| 内置验证集 Box，第 237 Epoch  | Precision(B) | 85.8% | 验证集 Box 精确率      |
| 独立测试集 chirp            | Precision    | 89.7% | 测试集 chirp 精确率更高  |
| 内置验证集 Box，第 237 Epoch  | mAP50(B)     | 0.760 | 验证集检测质量          |
| 内置验证集 Box all classes  | mAP@0.5      | 0.775 | 全类别 Box 表现       |
| 内置验证集 Mask all classes | mAP@0.5      | 0.764 | 全类别 Mask 表现      |
| 独立测试集 chirp            | F1-score     | 81.2% | 测试集综合精召表现        |

## 泛化能力结论

模型在独立测试集上的 chirp Recall 为 **73.9%**，与验证集中第 237 个 Epoch 的 Box Recall **73.9%** 完全一致，说明模型从验证集到独立测试集没有出现明显性能衰减。

同时，独立测试集 Precision 为 **89.7%**，高于验证集中对应 Epoch 的 Box Precision **85.8%**。这表明模型在测试集上保持了较好的误报控制能力。

综合来看，模型具备较稳定的泛化能力，当前主要问题不是验证集过拟合，而是整体召回上限和特定漏检样本的识别能力仍需提升。

# 5. 改进建议

## 1. 优先进行置信度阈值调优

当前 Box F1 最优区间约为 **0.300 ~ 0.500**，Mask 最优 F1 阈值为 **0.386**。建议围绕该区间进行系统阈值扫描。

可操作方向：

- 在独立测试集上测试阈值：**0.300、0.350、0.386、0.400、0.450、0.500**；
- 分别统计 TP、FP、FN、TN；
- 根据业务目标选择阈值：
  - 若偏向高可信筛选，选择 Precision 更高的阈值；

- 若偏向预警和少漏检，选择 Recall 更高的阈值；
- 建议输出 Precision-Recall-Threshold 表，明确不同阈值下的代价变化。

## 2. 对 22 个 FN 样本进行定向分析

独立测试集中存在 **22 个 chirp 漏检样本**，这是当前性能提升的第一优先级。

可操作方向：

- 汇总 FN 样本的信号强度、尺度、位置、形态；
- 检查 FN 是否集中在低信噪比、边界区域、小目标或特殊形态；
- 查看模型是否完全无候选框，还是候选置信度低于阈值；
- 若是低置信度导致漏检，优先通过阈值或校准处理；
- 若是无候选框导致漏检，需要从训练数据和模型学习能力入手。

## 3. 增强 chirp 困难样本的数据覆盖

当前 Recall 为 **73.9%**，说明仍有一部分 chirp 样本未被有效覆盖。建议针对 FN 类型扩充训练样本。

可操作方向：

- 增加低信噪比 chirp 样本；
- 增加弱信号、短时信号、边界位置 chirp 样本；
- 对 chirp 样本进行强度扰动、时间平移、局部遮挡或噪声混合增强；
- 在训练集中提高困难 chirp 样本采样权重。

## 4. 改进 noise 类别 Mask 分割质量

Mask noise mAP@0.5 为 **0.718**，是分割分支的相对弱项。

可操作方向：

- 检查 noise 掩膜标注是否一致，尤其是边界模糊区域；
- 将 noise 按形态或强度进行子类型统计，确认是否存在高混杂子类；
- 对 noise 区域增加边界更清晰的标注样本；
- 在分割训练中关注 Mask loss 对 noise 类别的收敛情况。

## 5. 建立分层评估机制

单一总体指标难以解释模型在哪些场景下失效。建议后续将测试集按信号特征分层。



可操作方向：

- 按 chirp 信号强度分层评估 Recall；
  - 按目标大小分层评估 mAP 与漏检率；
  - 按图像噪声水平分层评估 FP 与 FN；
  - 按位置区域统计漏检是否集中在边缘或局部区域；
  - 对每一层输出 Recall、Precision、F1-score，定位最主要的性能瓶颈。
- 

## 6. 结论

**yolo26n-set** 是一个训练稳定、泛化表现较一致的 YOLO 检测与分割模型。模型在验证集上 Box all classes mAP@0.5 为 **0.775**，Mask all classes mAP@0.5 为 **0.764**；在独立测试集 chirp 检测中取得 **73.9% Recall、89.7% Precision、76.8% Accuracy、81.2% F1-score**。

从性能结构看，模型当前更接近于 **高精度筛选器**，而不是高召回预警器。其主要优势是 chirp 预测可靠性较高，误报较少；主要短板是仍存在 **22 个 FN**，召回率尚未达到高召回预警场景的理想水平。

部署建议：

- 若业务目标是 **高可信 chirp 候选筛选**，当前模型具备初步部署价值；
- 若业务目标是 **尽可能减少 chirp 漏检**，建议暂不作为最终预警模型单独部署，应先完成阈值调优、FN 定向分析和困难样本增强；
- 下一阶段重点应放在 **提升 chirp Recall、分析漏检样本、优化阈值策略、改善 noise Mask 分割质量**。